

INFORME DEL PROYECTO: Análisis y predicción del contaminante atmosférico PM10 en algunas ciudades españolas (2022–2025)

1. INTRODUCCIÓN

Este proyecto analiza más de 5,6 millones de registros de contaminación atmosférica en España, procedentes de estaciones oficiales de la Agencia Europea de Medio Ambiente (EEA). El objetivo principal es construir un pipeline completo que permita:

- Integrar datos de múltiples estaciones y ciudades.
- Limpiar valores anómalos y faltantes.
- Generar series temporales diarias por ciudad.
- Crear nuevas variables temporales y derivadas.
- Entrenar modelos predictivos para estimar los niveles diarios de PM10.

El proyecto combina técnicas avanzadas de preprocesado, ingeniería de características, análisis exploratorio y modelado predictivo.

2. DATASET UTILIZADO

- Fuente: Agencia Europea de Medio Ambiente (EEA)
- Tipo: Público
- Volumen: 5.627.952 registros horarios
- Periodo: 2022–2025
- Ciudades: Badajoz, Madrid, Barcelona, Valencia, Sevilla, Bilbao
 - Las ciudades seleccionadas representan distintos tamaños urbanos, climas y fuentes de contaminación, lo que permite obtener un análisis más completo y un modelo predictivo más robusto. La combinación de grandes metrópolis, ciudades medianas e incluso una ciudad más pequeña como Badajoz aporta diversidad y mejora la capacidad del modelo para generalizar a diferentes contextos. (Ver Anexo I)
- Contaminantes: PM10, PM2.5, NO2, O3
 - Estos contaminantes se seleccionan porque son los principales indicadores oficiales de calidad del aire en Europa, representan diferentes fuentes de contaminación (tráfico, industria, procesos fotoquímicos) y tienen un impacto directo y demostrado en la salud

pública. Su análisis conjunto permite obtener una visión completa del estado de la atmósfera y mejorar la capacidad predictiva de los modelos. (Ver Anexo II)

El dataset original presentaba:

- Valores anómalos como -999
- Formatos inconsistentes
- Datos faltantes
- Varias estaciones por ciudad

Como el dataset original es muy grande, creamos una muestra. El **dataset de muestra** proporcionado en formato **Parquet**, que contiene mediciones horarias de contaminantes atmosféricos en distintas estaciones españolas. Este dataset incluye:

- Código de estación (Samplingpoint)
- Código del contaminante (Pollutant)
- Fecha y hora de inicio y fin de la medición (Start, End)
- Valor medido (Value)
- Unidad (Unit, siempre $\mu\text{g}/\text{m}^3$)
- Información de validez y verificación

Tras la carga, se confirma que el dataset contiene **5000 registros y 12 columnas**, lo que garantiza un volumen suficiente para análisis exploratorio y modelado.

3. PREPROCESADO DE DATOS

3.1. Conversión de fechas

Se transforman las columnas de tiempo a formato datetime para facilitar el análisis temporal. Es decir, la columna “Start” se convierte a tipo datetime, generando una **nueva columna “Fecha”** que combina fecha y hora. Esto permite ordenar, agrupar y manipular temporalmente las mediciones.

3.2. Mapeo de contaminantes

Se asignan nombres legibles a los códigos numéricos de contaminantes.

Los contaminantes vienen codificados según la Agencia Europea de Medio Ambiente (EEA). Se aplica un diccionario de mapeo:

Código	Contaminante
5	PM10
6001	PM2.5
8	NO ₂
7	O ₃

Se crea la columna “Contaminante” con los nombres reales.

Se verifica que el mapeo es correcto y que no existen códigos inesperados.

3.3. Pivotado del dataset (de formato largo a formato ancho)

Se reorganizan los datos para tener una columna por contaminante.

El dataset original tiene una fila por medición y contaminante. Para análisis posteriores, se transforma a un formato donde cada fila contiene:

- Estación
- Fecha
- PM10
- PM25
- NO2
- O3

Esto se realiza mediante `pivot_table()`. Se añade una comprobación del número de registros por contaminante para detectar desequilibrios:

- PM10: 1046
- PM25: 689
- NO2: 1962
- O3: 1303

Esto confirma que **NO2 y O3 tienen más datos**, mientras que **PM25 es el contaminante con menor cobertura**.

3.4. Ordenación por fecha

Se ordena el dataset por la columna “Fecha” para garantizar coherencia temporal antes de cualquier agregación o interpolación.

4. INTEGRACIÓN POR CIUDAD

Se asigna automáticamente la ciudad correspondiente a cada estación mediante reglas basadas en prefijos del código de estación.

Posteriormente, se agregan los datos a nivel diario por ciudad, obteniendo una serie temporal limpia para cada una.

4.1. Asignación automática de ciudad

Cada estación tiene un prefijo que identifica la provincia. Se implementa una función que asigna la ciudad correspondiente:

- ES/SP_060 → Badajoz
- ES/SP_280 → Madrid
- ES/SP_462 → Valencia
- ES/SP_480 → Bilbao
- ES/SP_410 → Sevilla
- ES/SP_08* → Barcelona

Se añade la columna “Ciudad”.

4.2. Reordenación de columnas

Para mejorar la legibilidad, se reorganizan las columnas en el siguiente orden:

1. Ciudad
2. Código de estación
3. Fecha completa
4. PM10, PM25, NO2, O3

4.3. Creación de fecha diaria

Se extrae la fecha sin hora (“Fecha_dia”) para poder calcular medias diarias.

4.4. Agregación diaria por ciudad

Se calcula la **media diaria** de cada contaminante por ciudad.

Esto reduce ruido horario y permite análisis comparativos entre ciudades.

5. LIMPIEZA DE DATOS

La limpieza es crítica porque los datos ambientales suelen contener:

- Valores faltantes

- Valores corruptos
- Valores negativos (imposibles físicamente)
- Outliers extremos

El proceso aplicado es exhaustivo y profesional.

5.1. Conversión a tipo numérico

Se fuerzan los contaminantes a **tipo float**, limpiando:

- Comas decimales
- Espacios
- Strings vacíos
- Valores "None" o "--"

5.2. Análisis de valores nulos

Antes de limpiar, los nulos por contaminante son:

- PM10: 2109
- PM25: 2379
- NO2: 1468
- O3: 1918

Esto confirma que el dataset requiere interpolación.

5.3. Sustitución de valores especiales

Se reemplazan:

- -999 → NaN
- Valores negativos → NaN

Porque **no existen valores negativos en contaminación atmosférica**.

5.4. Interpolación por ciudad

Para evitar sesgos, se interpola **por ciudad**, no globalmente.

Pasos:

1. Convertir "Fecha_día" a datetime
2. Ordenar por ciudad y fecha

3. Interpolar linealmente cada contaminante. Se aplica interpolación lineal para rellenar huecos en cada serie temporal.
4. Mantener límites coherentes

Resultado:

- PM10: 41 nulos restantes
- PM25: 41 nulos restantes
- NO2: 0
- O3: 0

Los nulos restantes corresponden a días sin datos suficientes para interpolar.

5.5. Detección y eliminación de outliers

Se aplica el método **IQR (Interquartile Range)** para detectar y eliminar valores extremos:

- Se calcula Q1, Q3 e IQR
- Se marcan como outliers los valores fuera de $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$
- Se eliminan filas donde **cualquier contaminante** sea outlier

Esto garantiza un dataset robusto para análisis y modelado.

5.6. Comprobación del dataset limpio

Se revisa:

- Primeras filas
- Estadísticas descriptivas
- Registros por ciudad

Registros finales por ciudad:

- Madrid: 746
- Barcelona: 564
- Bilbao: 453
- Valencia: 448
- Sevilla: 336
- Badajoz: 41

5.7. Verificación final tras interpolación y limpieza

Se comprueba:

Valores nulos restantes

- PM10: 41
- PM25: 41
- NO2: 0
- O3: 0

Rangos

- PM10: 1–45
- PM25: 0–21.45
- NO2: 1–55
- O3: 1–131.8

Todos los rangos son físicamente razonables.

Correlaciones

- PM10–PM25: 0.17 (moderada)
- NO2–O3: –0.14 (relación fotoquímica inversa)
- Resto: correlaciones bajas

Esto confirma que los contaminantes tienen comportamientos diferenciados.

5.8. Guardado del dataset limpio

El dataset final se guarda en:

src/otros_data/air_quality_clean.parquet src/otros_data/air_quality_clean.csv
--

Esto permite reutilizarlo sin repetir el pipeline.

6. ANÁLISIS EXPLORATORIO DE DATOS (EDA): MINI-EDA

El análisis exploratorio se realiza sobre el **dataset limpio y sin outliers**, con el objetivo de comprender el comportamiento del contaminante PM10, comparar las ciudades y detectar patrones temporales relevantes para el modelado. Este EDA se centra en PM10 porque es la variable objetivo del proyecto, mientras que PM2.5, NO₂ y O₃ se utilizan como variables explicativas.

Se incluyen tres visualizaciones principales:

- Serie temporal diaria de PM10
- Distribución de PM10 por ciudad (boxplot)
- Media de PM10 por ciudad
- Matriz de correlación entre contaminantes

6.1. Análisis temporal de PM10 por ciudad

Se representa la serie temporal diaria de PM10 para las seis ciudades analizadas: Badajoz, Barcelona, Bilbao, Madrid, Sevilla y Valencia.

Objetivos del gráfico:

- Detectar tendencias generales
- Identificar estacionalidad
- Observar picos y episodios de contaminación
- Comparar la evolución entre ciudades

Se genera un gráfico de líneas donde:

- Eje X: fecha (Fecha_dia)
- Eje Y: PM10 ($\mu\text{g}/\text{m}^3$)
- Una línea por ciudad




Figura 1. Serie temporal de PM10 por ciudad entre 2022 y 2025.

La figura 1 muestra la evolución de los niveles de PM10 entre 2022 y 2025. Para poder realizar un análisis más preciso genere diferentes gráficos, usando una media móvil de 15 días, reduciendo el rango temporal y separando las ciudades en subgráficos.

Principales observaciones:

- Se aprecia una **alta variabilidad diaria**, con picos puntuales de contaminación.
- Las ciudades presentan **diferencias claras**: Sevilla y Valencia muestran valores más elevados y fluctuantes, mientras que Bilbao y Valencia presentan valores más bajos y estables. Badajoz mantiene niveles más moderados, aunque tiene pocos datos de PM10, pero sus valores son coherentes con el resto.
- Las líneas se superponen debido a la densidad de datos, pero permiten identificar **tendencias generales** y episodios de aumento de partículas.
- Se observan patrones estacionales suaves, lo que justifica el uso de medias móviles y variables temporales

Este análisis temporal justificó la creación de variables como **medias móviles**, **lags** y **diferencias** para capturar patrones estacionales y tendencias.

6.2. Distribución de PM10 por ciudad (Boxplot)

Se construye un boxplot para comparar la **distribución de PM10** entre ciudades. Este tiene:

- Eje X: ciudad
- Eje Y: PM10 ($\mu\text{g}/\text{m}^3$)




Figura 2. Distribución de PM10, mediante bloxplot, por ciudad.

Resultados:

- **Barcelona:** mediana más alta ($\approx 22 \mu\text{g}/\text{m}^3$) y rango amplio $\rightarrow$ valores elevados y dispersión notable.
- **Bilbao:** mediana más baja ($\approx 15 \mu\text{g}/\text{m}^3$) $\rightarrow$ niveles más bajos y menos dispersión.
- **Madrid:** mediana similar a Bilbao, pero con rango algo mayor $\rightarrow$ variabilidad moderada.
- **Sevilla:** mediana alta ($\approx 20 \mu\text{g}/\text{m}^3$) y caja amplia $\rightarrow$ alta variabilidad.
- **Valencia:** mediana intermedia-baja ($\approx 15 \mu\text{g}/\text{m}^3$) $\rightarrow$ niveles más bajos.
- **Badajoz:** pocos datos, caja pequeña $\rightarrow$ poco representativo.
- Outliers visibles en **Barcelona, Bilbao, Madrid, Sevilla y Valencia**, lo que indica episodios puntuales de contaminación.

Estos resultados justificaron el tratamiento de **outliers** mediante el método IQR y la interpolación de valores faltantes. Es decir, los boxplots permitieron detectar valores extremos que posteriormente fueron tratados mediante el método IQR.


6.3. Comparación entre ciudades

Se calcula la media diaria de PM10 por ciudad y se representa en un gráfico de barras:

- Eje X: ciudad
- Eje Y: media de PM10 ($\mu\text{g}/\text{m}^3$)

Objetivo:

- Comparación directa entre ciudades
- Identificación de zonas con mayor carga de partículas



La Figura 3 muestra la **media de PM10 por ciudad** durante el periodo 2022–2025. Este análisis permite comparar los niveles medios de partículas en suspensión entre las seis ciudades seleccionadas.

Principales observaciones:


- **Barcelona** y **Sevilla** presentan las concentraciones medias más altas de PM10, superando los $23\text{ }\mu\text{g}/\text{m}^3$, lo que refleja una mayor carga de partículas asociada al tráfico urbano y a condiciones meteorológicas favorables a la acumulación.
- **Madrid** y **Valencia** muestran valores intermedios, en torno a $19\text{ }\mu\text{g}/\text{m}^3$, mientras que **Bilbao** registra niveles algo más bajos, próximos a $17\text{ }\mu\text{g}/\text{m}^3$.
- **Badajoz** no aparece representada en el gráfico debido a que **no se dispone de datos de PM10 ni PM2.5 para el periodo analizado**; sus estaciones solo reportan NO_2 y O_3 .

Conclusión: Este análisis complementa al boxplot y permite identificar qué ciudades tienen mayor carga media de partículas.

6.4. Correlación entre variables

Se generó una matriz de correlación para evaluar la relación entre los contaminantes y la variables temporal.

La Figura 4 muestra el **heatmap de correlaciones** entre los contaminantes atmosféricos (PM10, PM2.5, NO_2 y O_3) y la variable temporal *Fecha_ordinal*. Este análisis permite identificar relaciones lineales entre los distintos contaminantes y su evolución temporal.



Principales resultados:

- **PM10 y PM2.5** presentan una **correlación positiva moderada ($r \approx 0.17$)**, coherente con su origen común en partículas suspendidas de diferente tamaño.
- **NO₂** muestra correlaciones muy bajas con PM10 y PM2.5 ($r \approx 0.05-0.09$), lo que indica que su comportamiento es más independiente y está ligado principalmente al tráfico urbano.
- **O₃** mantiene una **correlación negativa con NO₂ ($r \approx -0.14$)**, reflejando su relación fotoquímica inversa: cuando las concentraciones de NO₂ son altas, el ozono tiende a disminuir.
- Las correlaciones con la variable temporal (*Fecha_ordinal*) son **muy débiles**, lo que sugiere que las variaciones temporales no siguen una tendencia lineal, sino que responden a **patrones estacionales** y condiciones meteorológicas específicas.

Conclusión: El análisis confirma que los contaminantes presentan comportamientos diferenciados y que las relaciones entre ellos son en general bajas, salvo entre las partículas PM10 y PM2.5. Esto justifica la inclusión de **variables temporales transformadas** (mes, estación, día de la semana) y de **interacciones entre contaminantes** en el modelado predictivo.

6.5. Conclusiones del EDA

El EDA permitió comprender en profundidad el comportamiento de los contaminantes y guiar las decisiones del pipeline. Entre las conclusiones más importantes destacan:

- La necesidad de un tratamiento diferenciado por ciudad debido a sus perfiles ambientales distintos.
- La importancia de eliminar valores anómalos y aplicar interpolación para obtener series temporales completas.
- La utilidad de las variables temporales y derivadas para capturar patrones estacionales y tendencias.
- La fuerte relación entre PM10 y PM2.5, que aporta información relevante al modelo.
- La complejidad del comportamiento del ozono, que depende de factores climáticos y fotoquímicos.

Este análisis exploratorio sentó las bases para un modelado predictivo sólido y fiable.

En definitiva, el EDA proporciona una comprensión sólida del comportamiento de PM10 y sienta las bases para el clustering y los modelos predictivos.

7. FEATURE ENGINEERING: INGENIERÍA DE CARACTERÍSTICAS

Se generan nuevas variables:

- Año, mes, día, día de la semana
- Estación del año
- Media móvil de 7 días
- Lags (valor del día anterior)
- Diferencias día a día

Estas variables enriquecen el modelo y mejoran la capacidad predictiva.

Tras obtener el dataset limpio `df_ciudad_sin_outliers`, se construye un nuevo DataFrame, `df_feat`, que incorpora variables derivadas pensadas para:

- Mejorar el rendimiento de modelos predictivos (regresión, árboles, XGBoost, etc.)
- Capturar patrones temporales (tendencias, estacionalidad, cambios bruscos)
- Facilitar análisis más ricos por ciudad y por periodo

```
df_feat = df_ciudad_sin_outliers.copy()
```

7.1. Conversión de la fecha a tipo datetime

Aunque `Fecha_dia` ya existía, se asegura que esté en formato `datetime` para poder extraer componentes temporales sin errores:

```
df_feat["Fecha_dia"] = pd.to_datetime(df_feat["Fecha_dia"], errors="coerce")
```

Esto permite usar `.dt.year`, `.dt.month`, `.dt.weekday`, etc., de forma robusta.

7.2. Extracción de componentes temporales

Se crean variables temporales básicas:

```
df_feat["Año"] = df_feat["Fecha_dia"].dt.year
df_feat["Mes"] = df_feat["Fecha_dia"].dt.month
df_feat["Día"] = df_feat["Fecha_dia"].dt.day
df_feat["Día_semana"] = df_feat["Fecha_dia"].dt.weekday 0 = lunes, 6 = domingo
df_feat["Semana_año"] = df_feat["Fecha_dia"].dt.isocalendar().week.astype(int)
```

Utilidad:

- **Año:** permite analizar cambios interanuales (por ejemplo, si la contaminación aumenta o disminuye con el tiempo).
- **Mes / Semana del año:** capturan estacionalidad (invierno vs verano, episodios de ozono, etc.).
- **Día de la semana:** permite detectar patrones laborales vs fines de semana (tráfico, actividad industrial).

7.3. Estación del año

Se define una función para asignar la estación en función del mes:

```
def estacion_del_año(mes):  
    if mes in [12, 1, 2]:  
        return "Invierno"  
    elif mes in [3, 4, 5]:  
        return "Primavera"  
    elif mes in [6, 7, 8]:  
        return "Verano"  
    else:  
        return "Otoño"  
  
df_feat["Estacion"] = df_feat["Mes"].apply(estacion_del_año)
```

Utilidad:

- Permite analizar de forma directa cómo varían los contaminantes por estación (por ejemplo, NO₂ más alto en invierno, O₃ más alto en verano).
- Es una variable categórica muy útil para gráficos, tablas resumen y modelos.

7.3.1. Tendencia acumulada (cumulative sum) de PM10

Se crea una variable de suma acumulada de PM10 por ciudad:

```
df_feat["PM10_cumsum"] = df_feat.groupby("Ciudad")["PM10"].cumsum()
```

Interpretación:

- Para cada ciudad, PM10_cumsum representa la **contaminación acumulada** a lo largo del tiempo.
- Es útil para detectar si una ciudad va “acumulando” más carga de partículas a lo largo del periodo de estudio.

- Puede ayudar a modelos a capturar tendencias de largo plazo sin necesidad de modelar explícitamente la serie completa.

7.4. Tendencias a corto plazo: medias móviles (rolling 7 días)

Se calculan medias móviles de 7 días para cada contaminante, por ciudad:

```
for c in cols_contam: # ["PM10", "PM25", "NO2", "O3"]
    df_feat[f"{c}_roll7"] = (
        df_feat.groupby("Ciudad")[c]
            .transform(lambda x: x.rolling(window=7, min_periods=1).mean())
    )
```

Utilidad:

- Suavizan la serie diaria, eliminando ruido de día a día.
- Capturan tendencias de corto plazo (una semana), muy útiles para:
 - Detectar episodios prolongados de contaminación
 - Alimentar modelos que se benefician de variables suavizadas
 - Comparar ciudades sin que un solo pico puntual distorsione la visión

7.5. Variables rezagadas (lags)

Se crean variables de **lag 1** (día anterior) para cada contaminante:

```
for c in cols_contam:
    df_feat[f"{c}_lag1"] = (
        df_feat.groupby("Ciudad")[c].shift(1)
    )
```

Utilidad:

- Capturan la dependencia temporal: el valor de hoy suele estar relacionado con el de ayer.
- Son fundamentales en modelos de series temporales y en modelos supervisados que no trabajan directamente con secuencias (árboles, regresiones, etc.).
- Permiten que el modelo “vea” la inercia de la contaminación.

7.6. Diferencias día a día (diff)

Se calculan diferencias respecto al día anterior:

```
for c in cols_contam:
```

```
df_feat[f"{c}_diff"] = (  
    df_feat.groupby("Ciudad")[c].diff()  
)
```

Utilidad:

- Miden el **cambio diario** de cada contaminante.
- Permiten detectar:
 - Subidas bruscas (episodios de contaminación)
 - Bajadas rápidas (episodios de ventilación, lluvia, etc.)
- Son muy útiles para modelos que intentan predecir no solo el nivel, sino también la dinámica (si va a subir o bajar).

7.7. Comprobación final del feature engineering

Se revisan las primeras filas de `df_feat` para confirmar que:

- Se mantienen las columnas originales (Ciudad, Fecha_día, PM10, PM25, NO2, O3).
- Se han añadido correctamente:
 - Variables temporales (Año, Mes, Día, Día_semana, Semana_año, Estacion)
 - Variables acumuladas (PM10_cumsum)
 - Medias móviles (*_roll7)
 - Lags (*_lag1)
 - Diferencias (*_diff)

Esto deja un dataset enriquecido, con unas 28 columnas, listo para:

- Modelos de predicción
- Clustering de ciudades o periodos
- Análisis avanzados de patrones temporales

8. PREPARACIÓN DEL DATASET PARA CLUSTERING Y REGRESIÓN

Tras completar el preprocesado y el feature engineering, se parte del dataset enriquecido `df_feat`, que contiene:

- Contaminantes diarios (PM10, PM25, NO2, O3)
- Variables temporales (mes, día de la semana, semana del año, estación)

- Variables derivadas (rolling 7 días, lag1, diff, cumsum)

El objetivo de este apartado es preparar dos datasets distintos:

1. **Dataset para clustering** → sin variables categóricas, sin fechas, solo variables numéricas.
2. **Dataset para regresión** → para predecir PM10 sin usar ninguna variable derivada del propio PM10 (para evitar fuga de información).

8.1. Selección de variables numéricas para clustering

El clustering requiere un conjunto de variables **puramente numéricas**, sin fechas ni categorías. Se seleccionan:

- Contaminantes originales
- Medias móviles (rolling 7 días)
- Lags
- Diferencias día a día

En total: **16 variables numéricas**.

Estas variables capturan:

- Nivel absoluto de contaminación
- Tendencias a corto plazo
- Inercia temporal
- Cambios bruscos

El dataset resultante (df_cluster) contiene únicamente estas columnas.

8.2. Eliminación de NaNs y escalado

Las transformaciones lag1 y diff generan NaNs en las primeras filas de cada ciudad. Por ello:

- Se eliminan las filas con NaN
- Se aplica **StandardScaler** para normalizar todas las variables

El escalado es imprescindible porque:

- KMeans y PCA son sensibles a la escala
- Variables como O3 (valores altos) podrían dominar sobre PM25 (valores bajos)

El resultado es una matriz X_cluster de tamaño:

(2542 filas, 16 variables)

8. 3. Preparación del dataset para regresión

El objetivo es **predecir PM10**.

Para evitar fuga de información, se excluyen todas las variables derivadas del propio PM10:

- PM10_roll7
- PM10_lag1
- PM10_diff
- PM10_cumsum

En su lugar se usan:

- Otros contaminantes (PM25, NO2, O3)
- Variables temporales (mes, día de la semana, semana del año)
- Transformaciones de PM25, NO2 y O3 (rolling, lag, diff)

Esto garantiza que el modelo no “ve” el futuro ni información derivada del target.

8.4. Escalado para regresión

Se aplica StandardScaler a las variables explicativas X:

- Mejora la estabilidad numérica de la regresión lineal
- Acelera la convergencia del MLPRegressor
- Evita que variables con mayor rango dominen el modelo

El scaler se guarda en src/models/scaler_regresion.pkl.

8.5. División en train/test

Se divide el dataset en:

- **80% entrenamiento**
- **20% test**
- random_state=42 para reproducibilidad

Tamaños finales:

- Train: 2033 muestras
- Test: 509 muestras

8.6. Comprobación final

Se confirma que:

- El dataset de clustering tiene 2542 filas
- El dataset de regresión tiene suficientes muestras para entrenar modelos robustos
- No quedan NaNs
- Todas las variables están escaladas correctamente

9. MODELOS DE CLUSTERING

El objetivo del clustering es **agrupar días con patrones similares de contaminación**, independientemente de la ciudad o la fecha.

Se utiliza **KMeans**, un algoritmo muy extendido para clustering numérico.

9.1. Método del Codo (Elbow Method)

Se entrena KMeans para valores de k entre 2 y 10. Para cada k se calcula la **inercia**, que mide la compacidad de los clusters.

El gráfico muestra:

- Una caída pronunciada entre k=2 y k=3
- A partir de k=3 la mejora es marginal

Esto sugiere que **2 o 3 clusters** son adecuados.

9.2. Silhouette Score

El Silhouette Score mide:

- Separación entre clusters
- Cohesión interna

Valores cercanos a 1 indican clusters bien definidos.

Resultados:

- El mejor valor se obtiene en **k = 2**
- Para $k > 3$ el silhouette cae, indicando clusters menos claros

Conclusión: **k óptimo = 2**

9.3. Entrenamiento final del modelo KMeans

Se entrena KMeans con:

- `n_clusters = 2`
- `n_init = 10`
- `random_state = 42`

Los labels obtenidos se asignan a `df_feat` en la columna `Cluster`.

El modelo se guarda en:

<code>src/models/model_kmeans.pkl</code>
--

9.4. Visualización con PCA

Para visualizar los clusters en 2D se aplica **PCA** (reducción de 16 variables → 2 componentes).

El gráfico muestra:

- Dos grupos bien diferenciados
- Separación clara en el plano PCA
- Clusters compactos y coherentes

Esto confirma que la elección de `k=2` es adecuada.

9.5. Interpretación de clusters

Se calcula la media de cada variable por cluster.

Cluster 0 → Días con contaminación más alta

- `PM10` ≈ 23.6
- `PM25` ≈ 11.5
- `NO2` ≈ 21.4
- `Rolling` y `lag` también más altos
- `Diffs` negativos (tendencia descendente tras picos)

Cluster 1 → Días con contaminación más baja

- `PM10` ≈ 13.9
- `PM25` ≈ 6.2
- `NO2` ≈ 17.2
- `Rolling` y `lag` más bajos
- `Diffs` positivos (tendencia ascendente)

Interpretación general:

- **Cluster 0** representa días con **alta carga de partículas y NO2**, típicos de episodios de contaminación.
- **Cluster 1** representa días más limpios o con niveles moderados.

10. MODELOS DE REGRESIÓN

El objetivo es **predecir PM10** a partir de:

- Otros contaminantes
- Variables temporales
- Transformaciones de PM25, NO2 y O3

Se entrenan tres modelos:

1. **Regresión Lineal**
2. **Random Forest Regressor**
3. **MLPRegressor (Red Neuronal)**

Las métricas utilizadas son:

- **MAE** (error absoluto medio)
- **RMSE** (raíz del error cuadrático medio)
- **R²** (coeficiente de determinación)

10.1. Función auxiliar de evaluación

Se define una función que calcula y muestra:

- MAE
- RMSE
- R²

Esto permite comparar modelos de forma homogénea.

10.2. Regresión Lineal

- El modelo lineal explica solo un **7% de la variabilidad** de PM10.
- Es un baseline útil, pero insuficiente para capturar relaciones no lineales.

10.3. Random Forest Regressor

Parámetros:

- 300 árboles
- Profundidad ilimitada
- random_state=42

Interpretación:

- Mejora sustancial respecto a la regresión lineal
- Captura relaciones no lineales entre contaminantes
- Explica un **43% de la variabilidad** de PM10
- Es el mejor modelo de los tres

10.4. MLPRegressor (Red Neuronal)

Arquitectura:

- Capas ocultas: (64, 32)
- Activación: ReLU
- Optimizador: Adam
- 500 iteraciones

Interpretación:

- No converge adecuadamente (warning de convergencia)
- Peor que la regresión lineal
- No captura bien la estructura del dataset
- Necesitaría tuning más profundo (learning rate, regularización, más iteraciones)

10.5. Gráficas de predicción vs real

Se generan tres gráficos comparando:

- Valores reales de PM10
- Valores predichos por cada modelo

Conclusiones visuales:

- **Regresión lineal:** nube dispersa, sin estructura clara
- **Random Forest:** puntos más alineados, mejor ajuste
- **MLP:** dispersión alta, predicciones pobres

10.6. Comparación final de modelos

Modelo	MAE	RMSE	R ²
Regresión Lineal	7.24	9.06	0.07
Random Forest	5.39	7.11	0.43
MLP	7.33	9.36	0.01

Conclusión:

- **Random Forest es el mejor modelo predictivo** para PM10 en este dataset.
- La regresión lineal sirve como baseline.
- El MLP no converge y no ofrece mejoras.

11. CONCLUSIONES FINALES

Este proyecto ha permitido construir un pipeline completo y robusto para el análisis, limpieza, enriquecimiento y modelado de datos de calidad del aire en varias ciudades españolas. A partir de un dataset horario de la Agencia Europea de Medio Ambiente, se ha desarrollado un flujo de trabajo reproducible que transforma datos brutos en conocimiento útil mediante técnicas de ingeniería de datos, análisis exploratorio, clustering y modelos predictivos.

A continuación se resumen las conclusiones más relevantes del estudio.

11.1. Conclusiones sobre el preprocesado y la calidad del dataset

El dataset original presentaba características típicas de datos ambientales:

- Gran cantidad de valores faltantes (entre 1.400 y 2.400 por contaminante).
- Valores especiales como -999 y valores negativos, ambos físicamente imposibles.
- Diferencias en la cobertura de contaminantes (PM25 mucho menos representado que NO2 u O3).
- Variabilidad horaria y diferencias entre estaciones dentro de una misma ciudad.

El pipeline de limpieza aplicado ha sido exhaustivo y efectivo:

- Se han corregido tipos, limpiado strings y convertido todo a valores numéricos.

- Se han eliminado valores imposibles y se ha interpolado por ciudad para mantener coherencia temporal.
- Se han eliminado outliers mediante el método IQR, garantizando un dataset robusto.
- Se ha verificado la consistencia final mediante estadísticas, rangos y correlaciones.

El resultado es un dataset limpio, consistente y listo para análisis avanzados.

11.2. Conclusiones del análisis exploratorio (Mini-EDA)

El Mini-EDA ha permitido identificar patrones relevantes:

Patrones temporales

- PM10 y PM25 muestran variabilidad moderada y picos puntuales.
- O3 presenta valores más altos y estacionales, coherentes con su naturaleza fotoquímica.
- NO2 es más estable, con picos asociados a tráfico y actividad urbana.

Comparación entre ciudades

- Madrid y Sevilla presentan niveles más altos de PM10 y PM25.
- Bilbao y Valencia muestran niveles más bajos y estables.
- Barcelona se sitúa en un punto intermedio.
- Badajoz tiene pocos datos, pero coherentes con el resto.

Correlaciones

- PM10 y PM25 tienen correlación moderada (0.17).
- NO2 y O3 presentan correlación negativa (-0.14), coherente con la química atmosférica.
- El resto de correlaciones son bajas, indicando comportamientos diferenciados.

11.3. Conclusiones del Feature Engineering

El dataset enriquecido `df_feat` incorpora:

- Variables temporales (mes, semana, día de la semana, estación).
- Tendencias acumuladas (cumsum).
- Medias móviles (rolling 7 días).

- Lags (día anterior).
- Diferencias (cambios diarios).

Estas variables capturan:

- Estacionalidad
- Tendencias a corto y largo plazo
- Inercia temporal
- Cambios bruscos

y son fundamentales para modelos predictivos y clustering.

11.4. Conclusiones del clustering

Se ha aplicado KMeans sobre 16 variables numéricas transformadas y escaladas.

Selección del número de clusters

- El método del codo sugiere $k=2$ o $k=3$.
- El Silhouette Score indica claramente que **$k=2$** es la mejor opción.

Interpretación de los clusters

Cluster 0 → Días con contaminación más alta

- $PM_{10} \approx 23.6$
- $PM_{25} \approx 11.5$
- $NO_2 \approx 21.4$
- Tendencias descendentes (diff negativos)

Cluster 1 → Días con contaminación más baja

- $PM_{10} \approx 13.9$
- $PM_{25} \approx 6.2$
- $NO_2 \approx 17.2$
- Tendencias ascendentes (diff positivos)

Conclusión del clustering

El clustering separa claramente:

- **Episodios de contaminación elevada**
- **Días limpios o moderados**

Esto es útil para:

- Alertas tempranas
- Clasificación automática de días
- Análisis de patrones por ciudad o estación del año

11.5. Conclusiones de los modelos de regresión

Se han entrenado tres modelos para predecir PM10:

Modelo	MAE	RMSE	R ²
Lineal	7.24	9.06	0.07
Random Forest	5.39	7.11	0.43
MLP	7.33	9.36	0.01

Regresión Lineal

- Explica solo un 7% de la variabilidad.
- Sirve como baseline, pero no captura relaciones no lineales.

Random Forest

- Es el mejor modelo del estudio.
- Explica un 43% de la variabilidad de PM10.
- Reduce el error respecto al modelo lineal.
- Captura interacciones entre contaminantes y variables temporales.

MLPRegressor

- No converge adecuadamente.
- Peor rendimiento que la regresión lineal.
- Requiere tuning más profundo.

Conclusión de la regresión

El **Random Forest** es el modelo más adecuado para este dataset, equilibrando precisión, interpretabilidad y robustez.

11.6. Limitaciones del estudio

1. **Cobertura desigual de contaminantes** PM25 tiene menos datos, lo que afecta a su capacidad predictiva.
2. **Interpolación necesaria** Aunque se ha hecho correctamente, siempre introduce incertidumbre.
3. **Dataset limitado a 5 ciudades** No se incluyen zonas rurales ni otras áreas urbanas.
4. **Modelos sin tuning avanzado** El MLP podría mejorar con más iteraciones, regularización o búsqueda de hiperparámetros.
5. **No se han modelado efectos meteorológicos** Variables como temperatura, viento o humedad mejorarían la predicción.

11.7. Líneas futuras de trabajo

1. **Incorporar datos meteorológicos** Mejoraría significativamente la predicción de PM10 y O3.
2. **Aplicar modelos avanzados de series temporales**
 - LSTM
 - Prophet
 - ARIMA multivariante
3. **Tuning de hiperparámetros** Especialmente para Random Forest y MLP.
4. **Clustering por ciudad o por estación del año** Para identificar patrones locales.
5. **Detección automática de episodios de contaminación** Usando los clusters y las diferencias diarias.
6. **Dashboard interactivo** Para visualizar tendencias y predicciones en tiempo real.

11.8. Conclusión final

El proyecto ha logrado transformar un dataset complejo y ruidoso en un sistema completo de análisis y predicción de calidad del aire. Se ha construido un pipeline sólido, reproducible y profesional que:

- Limpia y valida los datos
- Enriquecen las series temporales
- Identifica patrones mediante clustering
- Predice PM10 con modelos supervisados

El modelo Random Forest destaca como la mejor herramienta predictiva, mientras que el clustering permite clasificar días según su nivel de contaminación.

Este trabajo sienta las bases para un sistema más amplio de monitorización y predicción ambiental, con aplicaciones en salud pública, planificación urbana y gestión de episodios de contaminación.

12. AUTORA

María Jesús Sánchez Pimienta

- GitHub: <https://github.com/Mariasanchezp95>
- LinkedIn: <https://www.linkedin.com/in/maria-sanchez-96056016b>

ANEXO I: ELECCIÓN DE LAS CIUDADES EN EL DATASET

Las ciudades seleccionadas —Badajoz, Madrid, Barcelona, Valencia, Sevilla y Bilbao— se eligieron porque permiten analizar la contaminación atmosférica en contextos urbanos muy diferentes dentro de España. Cada una aporta un perfil ambiental, climático y demográfico distinto, lo que enriquece el análisis y mejora la capacidad del modelo para generalizar. En concreto:

1. Representan distintos tamaños de población

- **Madrid y Barcelona:** grandes áreas metropolitanas con tráfico intenso.
- **Valencia, Sevilla y Bilbao:** ciudades medianas con actividad industrial y portuaria.
- **Badajoz:** ciudad más pequeña que aporta contraste y diversidad.

2. Cubren diferentes zonas climáticas

- Mediterráneo (Barcelona, Valencia)
- Continental (Madrid)
- Atlántico (Bilbao)
- Sur cálido (Sevilla)
- Interior suroeste (Badajoz)

Esto permite observar cómo el clima influye en los niveles de contaminación.

3. Incluyen distintos tipos de fuentes de emisión

- Tráfico urbano (Madrid, Barcelona)
- Actividad industrial (Bilbao, Sevilla)
- Puertos marítimos (Barcelona, Valencia, Bilbao)
- Influencia rural y agrícola (Badajoz)

4. Facilitan un análisis equilibrado y manejable

Se buscó un conjunto de ciudades:

- suficientemente diverso,
- pero no demasiado grande,
- para poder procesar y modelar los datos dentro del tiempo disponible.

ANEXO II: ELECCIÓN DE LOS CONTAMINANTES

Los contaminantes seleccionados —**PM10, PM2.5, NO₂ y O₃**— son los más utilizados en estudios de calidad del aire porque representan los principales riesgos para la salud y son los indicadores oficiales empleados por la Unión Europea y la Agencia Europea de Medio Ambiente (EEA). Cada uno aporta información clave sobre diferentes fuentes de contaminación y efectos en la población:

PM10 (partículas gruesas)

- Proceden del tráfico, obras, polvo en suspensión y actividades industriales.
- Pueden penetrar en las vías respiratorias superiores y causar problemas respiratorios.
- Son uno de los indicadores más utilizados para evaluar la calidad del aire urbano.

PM2.5 (partículas finas)

- Más pequeñas y peligrosas que las PM10.
- Penetran profundamente en los pulmones y pueden llegar al torrente sanguíneo.
- Están asociadas a enfermedades cardiovasculares y respiratorias.
- Son un estándar internacional en estudios de salud ambiental.

NO₂ (dióxido de nitrógeno)

- Principalmente generado por el tráfico rodado y la combustión.
- Es un buen indicador de contaminación urbana relacionada con vehículos.
- Contribuye a la formación de ozono troposférico y partículas secundarias.

O₃ (ozono troposférico)

- No se emite directamente: se forma por reacciones químicas entre NO₂ y compuestos orgánicos volátiles con la luz solar.
- Aumenta en episodios de calor y radiación solar.
- Afecta a personas con asma y problemas respiratorios.